


Jakość danych i PII

Audyt kompletności i bezpieczeństwa

Tabela gold_customer_360 zawiera 28,813 wierszy i 19 kolumn. 67.3% wartości tax_id to NULL — to dane PII chronione column mask (WS2). Kompletność state: 100%, customer_name: 100%.

Metryka	Wartość	Status
Wiersze	28,813	OK
Kolumny	19	OK
% null tax_id	67.3%	PII — chronione
% bez zamówień	93.2%	Do analizy
Segmenty	4 (0-3)	OK

Metryki jakości danych



Jakość danych jest kluczowa dla modeli ML i AI asystentów. Lakehouse Monitoring (WS2) automatycznie wykrywa dryf rozkładów i anomalie.

Metodologia i kontekst analityczny

Tabela gold_customer_360 zawiera kolumny PII: tax_id (NIP/TIN firmy) i współrzędne GPS (lat, lon). W WS2 zabezpieczyliśmy te kolumny: column mask na tax_id (zwraca NULL dla nieuprawnionych użytkowników), row filter na state (ogranicza widoczność do wybranego regionu). Agent AI z WS4 NIE widzi tax_id — funkcja UC get_customer_profile celowo pomija tę kolumnę. To defense in depth: nawet jeśli ktoś obejdzie row filter, agent nie ujawni PII.

Porównania i benchmarki

Porównanie polityk ochrony PII w pipeline TechRetail Corp: (1) Column mask (WS2) — baza danych fizycznie nie zwraca tax_id do nieuprawnionych, (2) Row filter (WS2) — każdy widzi tylko swój region, (3) Agent guardrails (WS4) — system prompt zabrania ujawniania PII nawet jeśli dane są dostępne, (4) Brak PII w dokumentach RAG (WS3) — PDF-y nie zawierają tax_id. Każda warstwa działa niezależnie — złamanie jednej nie daje dostępu do PII.

Wnioski i rekomendacje

1. Column mask na tax_id (WS2) — PII nigdy nie opuszcza platformy bez autoryzacji.
2. Row filter na state (WS2) — ograniczenie widoczności per region dla menedżerów.
3. Regularne audyty kompletności w pipeline monitoringu Lakehouse Monitoring.
4. Alert na pct_null_tax > 70% — jeśli wzrasta, może brakć danych, nie mask.
5. Audyt uprawnień w Unity Catalog co kwartał: kto ma UNMASK na tax_id?